



UNIVERSITÉ PARIS 1 PANTHÉON SORBONNE
MASTER 2 MODÉLISATION ET MÉTHODES MATHÉMATIQUES EN ECONOMIE ET
FINANCE

Project - Numerical methods for optimization

Author :
Fevzi BOZCA

Supervisor :
Pierre GRUET

Academic Year : 2025 - 2026

10 février 2026

Table des matières

Introduction	3
1 Reformulation du Problème (Question 1)	3
2 Méthode de la Plus Forte Pente (Question 2)	3
2.1 Algorithme Utilisé	3
2.2 Résultats	4
2.3 Analyse	4
3 Méthode de Newton (Question 3)	4
3.1 Algorithme Utilisé	4
3.2 Résultats	4
3.3 Analyse	4
4 Gradient Conjugué Linéaire (Question 4)	4
4.1 Algorithme Utilisé	4
4.2 Résultats	4
4.3 Analyse	4
5 Comparaison avec les Bibliothèques (Question 5)	5
6 Optimisation Contrainte (Question 6)	5
6.1 Algorithme Utilisé	5
6.2 Résultats	5
6.3 Analyse	5
Conclusion	6

Introduction

Ce rapport présente la résolution du projet du cours *Numerical methods for optimization*. L'objectif est de déterminer l'allocation optimale d'un portefeuille d'actifs, en minimisant une fonction $J(x)$ qui choisit entre la minimisation du risque (variance) et la maximisation du rendement espéré.

Le problème est abordé en deux parties :

1. Une résolution **non contrainte**, utilisant des méthodes de descente classiques (Plus Forte Pente, Newton, Gradient Conjugué).
2. Une résolution **contrainte** (incluant les contraintes de positivité et budgétaires) avec des bibliothèques d'optimisation.

Les méthodes sans contraintes ont été implémentées manuellement en suivant les algorithmes du cours. Pour la partie contrainte, on analysera la performance des solveurs ('SciPy', 'NLOpt').

1 Reformulation du Problème (Question 1)

Le problème initial cherche à minimiser la fonction objectif suivante :

$$J(x) = \frac{1}{2}\text{Var}(R) - \phi E(R) \quad (1)$$

sous les contraintes $\sum_{i=1}^N x_i = 1$ et $x_i \geq 0$, avec $N = 12$ et $\phi = 5$.

La contrainte d'égalité est linéaire et permet de réduire la dimension du problème. Nous exprimons la variable x_N en fonction des autres :

$$x_N = 1 - \sum_{i=1}^{N-1} x_i \quad (2)$$

En substituant cette relation dans la variance l'espérance, nous obtenons une nouvelle fonction objectif $\tilde{J}(\tilde{x})$:

$$\tilde{J}(\tilde{x}) = \frac{1}{2}\tilde{x}^T H \tilde{x} + c^T \tilde{x} + \text{constante} \quad (3)$$

Les coefficients de la matrice Hessienne H et du vecteur c sont calculés à partir de la matrice de covariance Σ et du vecteur des rendements espérés $E(R)$. H étant dérivée d'une matrice de covariance, elle est symétrique définie positive, garantissant la convexité stricte du problème.

2 Méthode de la Plus Forte Pente (Question 2)

Ici on ne s'occupe pas des contraintes d'inégalité pour résoudre $\min_{\tilde{x} \in \mathbb{R}^{11}} \tilde{J}(\tilde{x})$.

2.1 Algorithme Utilisé

Nous utilisons la méthode de la plus forte pente (*Steepest Descent*). On a comme direction :

$$p_k = -\nabla \tilde{J}(x_k)$$

Le pas α_k est déterminé par *Line Search* satisfaisant les conditions de Wolfe (Algorithmes 2 et 3 du cours).

2.2 Résultats

- **Point de départ** : Vecteur nul $\mathbf{0}$.
- **Nombre d'itérations** : 5000 (Arrêt par nombre maximum d'itérations).
- **Valeur optimale** $\tilde{J}(x^*)$: 4.455363.

2.3 Analyse

La convergence n'est pas atteinte après 5000 itérations et la valeur finale (4.46) reste éloignée de l'optimum réel (≈ 3.79). On retrouve souvent cette erreur avec la méthode du gradient sur des problèmes mal conditionnés, où la direction du gradient oscille sans pointer directement vers le minimum. La matrice de covariance des actifs nous montre une forte corrélation, ce qui induit un conditionnement élevé de la Hessienne H .

3 Méthode de Newton (Question 3)

3.1 Algorithme Utilisé

Maintenant, on utilise la méthode de Newton (Algorithme 4). La direction de descente p_k est solution du système linéaire :

$$Hp_k = -\nabla \tilde{J}(x_k)$$

Puisque la fonction objectif est quadratique, l'approximation locale de second ordre utilisée par Newton est exacte.

3.2 Résultats

- **Nombre d'itérations** : 1 (Convergence immédiate).
- **Valeur optimale** $\tilde{J}(x^*)$: 3.792216.

3.3 Analyse

La convergence en une seule itération confirme qu'on travail sur un problème quadratique et la bonne implémentation de l'algorithme. C'est la méthode la plus efficace en termes de nombre de pas pour ce problème sans contrainte.

4 Gradient Conjugué Linéaire (Question 4)

4.1 Algorithme Utilisé

Nous utilisons l'algorithme du Gradient Conjugué (*Linear Conjugate Gradient*, Algorithme 7) pour résoudre le système linéaire $Hx = -c$ équivalent à l'annulation du gradient.

4.2 Résultats

- **Nombre d'itérations** : 14.
- **Valeur optimale** $\tilde{J}(x^*)$: 3.792216.

4.3 Analyse

La méthode converge en un nombre d'itérations très proche de la dimension du problème ($N - 1 = 11$), atteignant la même précision que la méthode de Newton mais avec un coût de mémoire inférieur (pas de stockage ni de factorisation de la Hessienne). Le dépassement

du nombre de pas de la dimension du problème est peut être dû aux erreurs d'arrondi numérique en virgule flottante.

5 Comparaison avec les Librairies (Question 5)

Nous comparons nos résultats avec les solveurs des librairies SciPy (Python) et NLOpt.

TABLE 1 – Comparaison des optimums trouvés

Implémentation	Algorithme	Type	Résultat (J^*)
Code Projet	Newton	Non Contraint	3.792216
SciPy	BFGS	Non Contraint	3.792216
NLOpt	L-BFGS	Non Contraint	3.792216
SciPy	SLSQP	Contraint	8.537083

Conclusion : Nos algorithmes écrit à la main (Newton, Gradient Conjugué) obtiennent des résultats identiques aux solveurs de Scipy et NLOpt sans contraintes (BFGS) avec une précision de (10^{-6}) , ce qui montre que le code est juste.

6 Optimisation Contrainte (Question 6)

Nous résolvons enfin le problème complet en prenant en comptes les contraintes d'inégalité :

$$x_i \geq 0 \quad \text{et} \quad \sum_{i=1}^{N-1} x_i \leq 1$$

6.1 Algorithme Utilisé

Pour cette partie, on utilise l'algorithme **SLSQP** (*Sequential Least Squares Programming*) dans SciPy. SLSQP est une méthode de programmation quadratique séquentielle qui résout le problème d'optimisation non linéaire avec contrainte en générant une suite de sous-problèmes quadratiques approchant le Lagrangien de la fonction originale. C'est une méthode standard et robuste pour les problèmes de taille moyenne avec contraintes.

6.2 Résultats

- **Valeur optimale** $J(x^*)$: 8.537083.
- **Respect des contraintes** : Somme des poids = 1.000000, Poids min ≥ 0 .

6.3 Analyse

On observe un écart significatif entre l'optimum non contraint (3.79) et l'optimum contraint (8.53). Cette augmentation de la fonction de coût représente le "coût" des contraintes de positivité. Dans le cas sans contrainte, on utilisait beaucoup la vente à découvert (poids négatifs) pour réduire le risque. L'interdiction de ces positions force le portefeuille sur une frontière efficiente moins favorable.

Conclusion

Ce projet a permis l'implémentation d'algorithmes fondamentaux d'optimisation numérique. La méthode de **Newton** s'est révélée être la plus performante pour le problème quadratique simple, convergeant en une seule itération. Pour le problème réel avec contraintes, l'utilisation du solveur **SLSQP** de SciPy a permis d'obtenir une solution robuste respectant les contraintes budgétaires et de positivité, mettant en évidence l'impact financier important de ces restrictions sur la performance théorique du portefeuille.